

# Statistik II - Sitzung 5

Lena Masch

Institut für Politikwissenschaft

Sitzung 5


# Statistik II - Sitzung 5

- 1 Organisatorisches
- 2 Wiederholung der Logik des Testens
- 3 Weitere Grundlagen des Testens
- 4 Die Varianzanalyse (F-Test)
- 5 Varianzanalyse (ANOVA)


# Organisatorisches

- Umfrage bitte ausfüllen! (s. Link im Learnweb)
- Chi<sup>2</sup>-Test für Zuhause folgt (nun endlich!)
- Tutorien diese Woche zum Themenbereich "Testen"

# Wiederholung



# Wiederholung



# Wiederholung

- Fiktive Umfrage unter 100 Studierenden zur Social Media Nutzung
- Nutzen Studierende der Politikwissenschaft mehr Social Media als Andere (im Durchschnitt 3 Stunden)?

## One-Sample Statistics

	N	Mean	Std. Deviation	Std. Error Mean
social_d	100	3.8072	.65241	.06524

## One-Sample Test

Test Value = 3

	t	df	Significance		Mean Difference	95% Confidence Interval of the Difference	
			One-Sided p	Two-Sided p		Lower	Upper
social_d	12.373	99	<.,001	<.,001	.80720	.6778	.9367

## One-Sample Effect Sizes

Standardizer <sup>a</sup>	Point Estimate	95% Confidence Interval	
		Lower	Upper

# Wiederholung

- Fiktive Umfrage unter 100 Studierenden zur Social Media Nutzung
- Nutzen Studierende der Politikwissenschaft mehr Social Media als Andere (im Durchschnitt 3 Stunden)?

```
> t.test(student_data$social_d, mu = 3)
```

One Sample t-test

```
data: student_data$social_d  
t = 12.373, df = 99, p-value < 2.2e-16  
alternative hypothesis: true mean is not equal to 3  
95 percent confidence interval:  
 3.677753 3.936657  
sample estimates:  
mean of x  
 3.807205
```

# Wiederholung

- Vergleich zweier Gruppen
- Gibt es einen Unterschied zwischen den Geschlechtern im Social Media Nutzungsverhalten?
- Was nehmen wir an?
- Wie ist vorzugehen?



# Wiederholung

- Vergleich zweier Gruppen
- Gibt es einen Unterschied zwischen den Geschlechtern im Social Media Nutzungsverhalten??

## T-Test

**Group Statistics**

	gender	N	Mean	Std. Deviation	Std. Error Mean
social_d	1.00	46	3.8474	.64910	.09571
	2.00	54	3.7730	.65934	.08972

**Independent Samples Test**

		Levene's Test for Equality of Variances						t-test for Equality of Means	
		F	Sig.	t	df	Significance		Me	
social_d	Equal variances assumed	.477	.492	.567	98	.286	.572		
	Equal variances not assumed			.568	95.939	.286	.572		

# Wiederholung

- Vergleich zweier Gruppen
- Gibt es einen Unterschied zwischen den Geschlechtern im Social Media Nutzungsverhalten??

```
> t.test(student_data$social_d ~student_data$gender)
```

```
Welch Two Sample t-test
```

```
data: student_data$social_d by student_data$gender  
t = 0.56752, df = 95.939, p-value = 0.5717  
alternative hypothesis: true difference in means between group 1  
95 percent confidence interval:  
 -0.1859542  0.3348568  
sample estimates:  
mean in group 1 mean in group 2  
      3.847409      3.772957
```


# Probleme des statistischen Tests

- **$\alpha$ -Fehler oder Fehler Type I** – Ablehnung von  $H_0$  aufgrund des Stichprobenergebnisses, obwohl  $H_0$  in GG zutrifft
- **$\beta$ -Fehler oder Fehler Type II** – Nicht-Ablehnung von  $H_0$  aufgrund des Stichprobenergebnisses, obwohl  $H_0$  in GG nicht zutrifft

<i>Entscheidung aufgrund Stichprobe</i>	$H_0$ in GG wahr	$H_0$ in GG falsch
$H_0$ wird <b>nicht abgelehnt</b>	Korrektter Schluss	$\beta$ -Fehler (Type II)
$H_0$ wird <b>abgelehnt</b>	$\alpha$ -Fehler (Type I)	Korrektter Schluss

# Probleme des statistischen Tests

**Type I error**  
(false positive)



**Type II error**  
(false negative)



<https://economics.stackexchange.com/questions/27677/type-i-error-type-ii-error-pregnancy-test-analogy-is-it-legit>

# Logik der statistischen Signifikanz

- Aufgrund der Logik des statistischen Tests (von  $H_0$ ) primäres Interesse an Vermeidung / Minimierung von  $\alpha$ -Fehler (Type I)
- Wahrscheinlichkeit des  $\alpha$ -Fehler -  $H_0$  in GG ist wahr, wird aber aufgrund Stichprobenwerts abgelehnt - soll möglichst gering sein
- Annahme, dass eine Wahrscheinlichkeit des  $\alpha$ -Fehler von unter 5% genügend Sicherheit bietet
- $\alpha$ -Wahrscheinlichkeit (= probability, p) soll also  $< 5\%$  oder  $< .05$  sein
- **$p < .05 \Rightarrow 95\%$ -Signifikanzniveau!**

# Logik der statistischen Signifikanz

- Wir lehnen also die Nullhypothese  $H_0$  ab (und bestätigen indirekt die Alternativhypothese  $H_A$ ), wenn wir sicher sein können, dass - unter der Annahme, dass es in der GG keinen Zusammenhang gibt – der über die Stichprobe erhaltene (Zusammenhangs-)Wert in weniger als 5 von 100 Stichproben vorkommt.

# Logik der statistischen Signifikanz

- Wir lehnen also die Nullhypothese  $H_0$  ab (und bestätigen indirekt die Alternativhypothese  $H_A$ ), wenn wir sicher sein können, dass der über die Stichprobe erhaltene (Zusammenhangs-)Wert in weniger als 5 von 100 Stichproben unter der Annahme vorkommt, dass es in der GG keinen Zusammenhang gibt
- Weitere Signifikanzniveaus sind das  $p < .01$  (99%) und das  $p < .001$  (99.9%) Signifikanzniveau
  - ▶ Ablehnung von  $H_0$ , wenn der über die Stichprobe erhaltene Wert in weniger als 1 von 100 ( $p < .01$ ) bzw. 1 von 1000 ( $p < .001$ ) Stichproben unter Annahme von  $H_0$  in GG vorkommt

# Warum $p < .05$ ?

- 'The criterion of 95% confidence, or a .05-probability, forms the basis of modern statistics, and yet there is very little justification for it. How it arose is a complicated mystery to unravel.' (Fields 2013: 52)
- Verkürzt gesagt:  $p < .05$  (bzw.  $p < .01$ ,  $p < .001$ ) hat sich einfach so eingebürgert.



# Warum $p < .05$ ?

## Auswahl des p-Levels muss reflektiert werden

Da - wie wir noch lernen werden - der Signifikanztest von einigen Faktoren abhängig ist, muss die Festlegung des Signifikanzniveaus (der Fehler-Wahrscheinlichkeit  $p$ ) immer nach theoretischer Überlegung erfolgen: Welche Wahrscheinlichkeit scheint mir als ForscherIn gering genug, um ein Ergebnis als gesichert bezeichnen zu können?


## Auswahl des p-Levels VOR statistischem Test

Die Festlegung des Signifikanzniveaus für die Widerlegung der Nullhypothese erfolgt immer VOR dem statistischen Test!


## Exkurs - einseitiger/zweiseitiger Test

- Ein zweiseitiger Signifikanztest wird dann vorgenommen, wenn **keine** Erwartung an die Richtung des Unterschieds zwischen zwei Gruppen vorliegt
- und die zugrundeliegende Verteilung zwei kritische Bereiche (positiv und negativ) hat, z.B. t- und z-Verteilungen
  - ▶ Dann muss der  $\alpha$ -Fehler nach beiden Seiten abgesichert werden. Der zu erreichende Wahrscheinlichkeitswert liegt dann **nicht** bei  $p < .05$ , sondern bei  $p < .05/2 = .025$ !


# Exkurs - einseitiger/zweiseitiger Test



One tail (less than alternative)  
Critical region 0.05



One tail (greater than alternative)  
Critical region 0.05



Two tail (non-directional)  
Critical region  $0.025 + 0.025 = 0.05$

# Exkurs - einseitiger/zweiseitiger Test

- Ein zweiseitiger Signifikanztest wird dann vorgenommen, wenn **keine** Erwartung an die Richtung des Unterschieds zwischen zwei Gruppen vorliegt
  - ▶ Dann muss der  $\alpha$ -Fehler nach beiden Seiten abgesichert werden. Der zu erreichende Wahrscheinlichkeitswert liegt dann **nicht** bei  $p < .05$ , sondern bei  $p < .05/2 = .025$ !
- Ein einseitiger Signifikanztest wird dann vorgenommen, wenn eine Erwartung an die Richtung des Unterschieds zwischen zwei Gruppen vorliegt.
  - ▶ Dann muss der  $\alpha$ -Fehler nur nach einer Seite abgesichert werden. Der zu erreichende Wahrscheinlichkeitswert liegt dann wie angenommen bei  $p < .05$ !

## Exkurs - einseitiger/zweiseitiger Test

**Achtung:  $p < .05 \Rightarrow .025!$**

Für das 95%-Signifikanzniveau ( $p < .05$ ) muss in einem zweiseitigen Test der Wahrscheinlichkeitswert  $p = .025$  (= z-Wert: 1.96) erreicht werden. In einem einseitigen Test reicht der Wahrscheinlichkeitswert  $p = .05$  aus (= z-Wert: 1.65).

# Statistische Signifikanz

- Wir haben in den letzten Sitzungen die Signifikanz bzw. das Signifikanz-Niveau von Ergebnissen berechnet.
- Dabei war das Ziel, den  $\alpha$ -Fehler weitestgehend auszuschließen bzw. die Wahrscheinlichkeit seines Auftretens möglichst gering zu halten.
- Wiederholung: Der  $\alpha$ -Fehler bezeichnet den Fehler, dass wir aufgrund der Stichproben-Ergebnisse die Nullhypothese widerlegen, obwohl die Nullhypothese in der Grundgesamtheit zutrifft.

# Statistische Signifikanz

- Wie gehen wir aber im Forschungs-Alltag mit der Signifikanz um?
- Leider ist die Interpretation der Signifikanz schwieriger oder: weniger eindeutig als angenommen – und wird oft fehlerhaft interpretiert
  - ▶ Siehe *Haller und Krauss 2002*
- Statistische Signifikanz besagt nur, wie wahrscheinlich das Auftreten eines Stichprobenwertes unter angenommener Gültigkeit der Nullhypothese in GG ist

# Statistische Signifikanz

- Daher lässt die Signifikanz eines Stichprobenwertes auf dem 95%-Niveau streng genommen nur folgende Aussagen zu:
  - ▶ Wenn die Nullhypothese in der GG zutrifft, taucht der gefundene oder ein noch extremerer Stichproben-Wert in weniger als 5% aller aus der GG gezogenen Stichproben auf ODER
  - ▶ Da der gefundene oder ein noch extremerer Wert nur in 5 von 100 Stichproben aus einer GG, in der die Nullhypothese zutrifft, auftauchen würde, können wir die Annahme, dass die Nullhypothese in der GG zutrifft, als unwahrscheinlich ablehnen



# Statistische Signifikanz

- Was wir NICHT aufgrund der Signifikanz sagen können:
  - ▶ Dieser Wert spiegelt mit 95% Wahrscheinlichkeit den Wert der Grundgesamtheit wider
- Für die Anwendung in der täglichen Arbeit:
  - ▶ Da der Wert A auf dem 95%-Niveau signifikant ist, können wir die Nullhypothese ablehnen
  - ▶ Der Wert A ist auf dem 99%-Niveau signifikant. Wir akzeptieren daher vorläufig die Alternativhypothese / Die Alternativhypothese kann vorläufig bestätigt werden

# Ursachen der statistischen Signifikanz

- Welche Faktoren beeinflussen das Ergebnis des statistischen Tests (und damit die Entscheidung über signifikant oder nicht)?
  - ▶ Klar: Die **Größe des Effektes** (des Unterschiedes zwischen Gruppen bzw. die Stärke des Effekts/Zusammenhangs)
  - ▶ Auch klar: Das gewählte **Wahrscheinlichkeitsniveau** ( $p < .05$ ,  $< .01$ ,  $< .001$ )
  - ▶ die **Stichprobengröße**
  - ▶ das spezifische Test- oder Analyseverfahren
  - ▶ die Anzahl der zu vergleichenden Gruppen
  - ▶ die Entscheidung ob ein- oder zweiseitig

# Varianzanalyse (ANOVA)

- Die Varianzanalyse nutzt die Varianz (Streuung), um Hypothesen zu testen
- zurückzuführen auf R.A. Fisher
- Varianzanalyse, analysis of variance (ANOVA), F-Test
- Vergleich von mehr als zwei Gruppen
- einfache Varianzanalyse (one-way ANOVA) und für Messwiederholungen
- oftmals in der Psychologie angewandt (Experimente)

# Varianzanalyse (ANOVA)

- in der Psychologie klassischerweise ein Vergleich als Kontroll- und Experimentalgruppen
- die unabhängige Variable ist dabei ein Faktor (kategorielle Variable)
- es ist nicht möglich, mehrere t-Tests durchzuführen, um Gruppen zu vergleichen (alpha-Fehler)

# Was ist die Varianzanalyse (ANOVA)? F-Test?

- Der F-Test wird verwendet, um zu prüfen, ob mehrere Gruppen signifikant unterschiedliche Mittelwerte haben.
- F-Tests verwendet werden, um zu analysieren, ob verschiedene Gruppen signifikante Unterschiede in bestimmten Merkmalen aufweisen.
- Der Test basiert auf dem Vergleich der Streuungen (Varianzen) innerhalb und zwischen Gruppen.
- Die Alternativhypothese ist ungerichtet. Sie geht davon aus, dass ein oder mehrere Gruppen einen Einfluss auf die abhängige Variable haben
- Die Nullhypothese geht davon aus, dass die beobachteten Werte der Gruppen sich nicht unterscheiden

# Die F-Statistik

Die F-Statistik wird wie folgt berechnet:

$$F = \frac{\text{Zwischen-Gruppen-Varianz}}{\text{Innerhalb-Gruppen-Varianz}} = \frac{\frac{QS_{\text{zwischen}}}{k-1}}{\frac{QS_{\text{innerhalb}}}{N-k}} \quad (1)$$

- **QS**: Quadratsumme
- **k**: Anzahl der Gruppen
- **N**: Gesamtanzahl der Beobachtungen

Ein hoher F-Wert deutet darauf hin, dass die Unterschiede zwischen den Gruppen signifikant sind.

# Quadratsummen (QS)

- **Zwischen-Gruppen-Quadratsumme ( $QS_{\text{zwischen}}$ ):** Variation zwischen den Mittelwerten der Gruppen.

$$QS_{\text{zwischen}} = \sum_{i=1}^k n_i (\bar{X}_i - \bar{X})^2$$

- **Innerhalb-Gruppen-Quadratsumme ( $QS_{\text{innerhalb}}$ ):** Variation innerhalb jeder Gruppe.

$$QS_{\text{innerhalb}} = \sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2$$

- **Gesamt-Quadratsumme ( $QS_{\text{gesamt}}$ ):**

$$QS_{\text{gesamt}} = \sum_{i=1}^N (X_i - \bar{X})^2$$

# Exkurs: Kleines Beispiel F-Statistik

Betrachten wir drei Gruppen mit folgenden Datenpunkten:

Gruppe 1: 5, 6, 7    Gruppe 2: 8, 9, 10    Gruppe 3: 10, 11, 12

- **Gesamtmittelwert** ( $\bar{X}$ ): 8.5
- Berechnung der Mittelwerte jeder Gruppe:

$$\bar{X}_1 = 6$$

$$\bar{X}_2 = 9$$

$$\bar{X}_3 = 11$$

- Berechnung der Quadratsummen:

$$\begin{aligned} QS_{\text{zwischen}} &= 3 \times ((6 - 8.5)^2 + (9 - 8.5)^2 + (11 - 8.5)^2) \\ &= 40.5 \end{aligned}$$

$$\begin{aligned} QS_{\text{innerhalb}} &= (5 - 6)^2 + (6 - 6)^2 + (7 - 6)^2 + \\ &\quad (8 - 9)^2 + (9 - 9)^2 + (10 - 9)^2 + \\ &\quad (10 - 11)^2 + (11 - 11)^2 + (12 - 11)^2 \\ &= 6 \end{aligned}$$



## Exkurs: Kleines Beispiel F-Statistik

$$\text{Mittlere QS}_{\text{zwischen}} = \frac{\text{QS}_{\text{zwischen}}}{k - 1} = \frac{40.5}{2} = 20.25$$

$$\text{Mittlere QS}_{\text{innerhalb}} = \frac{\text{QS}_{\text{innerhalb}}}{N - k} = \frac{6}{6} = 1$$

$$F = \frac{\text{Mittlere QS}_{\text{zwischen}}}{\text{Mittlere QS}_{\text{innerhalb}}} = \frac{20.25}{1} = 20.25$$

Ein hoher F-Wert (hier 20.25) könnte darauf hindeuten, dass die Gruppenmittelwerte signifikant unterschiedlich sind.

# Interpretation des Ergebnisses

- Wenn der berechnete F-Wert größer ist als der kritische F-Wert aus der F-Tabelle, lehnen wir die Nullhypothese ab.
- Die Nullhypothese besagt, dass alle Gruppenmittelwerte gleich sind.
- Hier: Ein hoher F-Wert deutet darauf hin, dass es signifikante Unterschiede zwischen den Gruppen gibt.
- Hohe Werte mit kritischen Werten oder ausgegeben Signifikanz-Niveau abgleichen

# Zusammenfassung

- Der F-Test hilft uns, zu analysieren, ob es signifikante Unterschiede zwischen Gruppen gibt.
- Er basiert auf dem Vergleich der Varianz zwischen und innerhalb von Gruppen.
- Ein signifikanter F-Wert weist darauf hin, dass die Gruppenmittelwerte wahrscheinlich unterschiedlich sind.
- Weitere Überlegungen:
  - ▶ Dieses Beispiel nutzt gleiche Fallzahlen pro Gruppe, dies wird oft als Voraussetzung für die ANOVA gesehen (equal sample size)
  - ▶ Wichtig ist jedoch, dass die Varianz zwischen den Gruppen gleich ist (Test auf Varianzgleichheit) oder Anwendung von robusten Tests wie Welch's ANOVA
  - ▶ soll analysiert werden, zwischen welchen Gruppen signifikante Unterschiede vorliegen, müssen Posthoc-Tests durchgeführt werden
  - ▶ Posthoc-Tests korrigieren den alpha-Fehler für das multiple Testen, damit die Irrtumswahrscheinlichkeit insgesamt auf dem gewählten Niveau liegt (und nicht größer ausfällt), z.B. Bonferroni

- Harry Potter und politische Einstellungen?

Politics

## Harry Potter and the Deathly Donald

Diana C. Mutz, *University of Pennsylvania*

### ABSTRACT

Few empirical studies suggest that fictional stories can influence political opinions. Nonetheless, in this study I demonstrate the relevance of Harry Potter consumption to oppositional attitudes toward Donald Trump and his worldview. Using multivariate observational models and panel data from 2014 to 2016, results suggest that the lessons of the Harry Potter series have influenced levels of opposition to punitive policies and support for tolerance of groups considered outside the American mainstream. Further, they predict public reactions to Donald Trump above and beyond their influence on policies consistent with his views.

# Varianzanalyse


- Links-Rechts-Selbsteinstufung und Harry Potter Haus Präferenz
- Mittelwerte, Standardabweichung und Varianzanalyse

```
>
> tapply(ds_filtered$PE01_01, ds_filtered$hp, mean, na.rm = TRUE)
Gryffindor Hufflepuff Ravenclaw Slytherin
 2.866667   3.363636   2.875000   3.142857
> tapply(ds_filtered$PE01_01, ds_filtered$hp, sd, na.rm = TRUE)
Gryffindor Hufflepuff Ravenclaw Slytherin
 0.9904304  1.5666989  1.0246951  1.5735916
> summary(aov(PE01_01 ~ hp, data = ds_filtered))
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
hp	3	2.09	0.6979	0.456	0.714
Residuals	45	68.89	1.5308		

# Varianzanalyse

- Links-Rechts-Selbsteinstufung und Harry Potter Haus Präferenz



# Varianzanalyse

- Links-Rechts-Selbsteinstufung und Harry Potter Haus Präferenz
- Beispiel einer Power-Analyse für eine große Effekstärke

```
> pwr::pwr.anova.test(k = 4, f = 0.35, power = 0.8, sig.level = 0.05)
```

```
Balanced one-way analysis of variance power calculation
```

```
      k = 4
```

```
      n = 23.25056
```

```
      f = 0.35
```

```
sig.level = 0.05
```

```
power = 0.8
```

NOTE: n is number in each group

# Varianzanalyse

- Links-Rechts-Selbsteinstufung und Harry Potter Haus Präferenz
- Beispiel einer Power-Analyse für eine mittlere Effekstärke

```
>  
> pwr::pwr.anova.test(k = 4, f = 0.15, power = 0.8, sig.level = 0.05)
```

Balanced one-way analysis of variance power calculation

```
      k = 4  
      n = 122.1209  
      f = 0.15  
sig.level = 0.05  
power = 0.8
```

NOTE: n is number in each group



# Varianzanalyse

- Links-Rechts-Selbsteinstufung und Harry Potter Haus Präferenz
- Beispiel einer Welch's ANOVA (ohne Annahme der Varianzgleichheit)

```
>  
> oneway.test(PE01_01 ~ hp, data = ds_filtered)  
  
One-way analysis of means (not assuming equal variances)  
  
data: PE01_01 and hp  
F = 0.33082, num df = 3.000, denom df = 18.549, p-value =  
0.8031  
>
```

# Varianzanalyse

- Links-Rechts-Selbsteinstufung und Harry Potter Haus Präferenz
- Beispiel eines Posthoc-Tests

```
> TukeyHSD(aov(PE01_01 ~ hp, data = ds_filtered))
```

```
Tukey multiple comparisons of means  
95% family-wise confidence level
```

```
Fit: aov(formula = PE01_01 ~ hp, data = ds_filtered)
```

```
$hp
```

		diff	lwr	upr	p adj
Hufflepuff-Gryffindor	0.496969697	-0.8132394	1.8071788	0.7433548	
Ravenclaw-Gryffindor	0.008333333	-1.1779028	1.1945694	0.9999976	
Slytherin-Gryffindor	0.276190476	-1.2346291	1.7870100	0.9614486	
Ravenclaw-Hufflepuff	-0.488636364	-1.7814069	0.8041342	0.7453908	
Slytherin-Hufflepuff	-0.220779221	-1.8166099	1.3750514	0.9826112	
Slytherin-Ravenclaw	0.267857143	-1.2278646	1.7635789	0.9636223	

```
> |
```

# Ausblick

- nächste Woche: Zusammenhang des Testens und der Regression
- nächste Einheit: multivariate Regression
- Tipps: Tutorienbesuch und zusätzliche Literatur auf Learnweb beachten